Отчёт

Студент: Турко С.А. Группа: M16-522

Link: https://github.com/sergeyturko/DSBDA_HW1

Задача.

Необходимо найти самое длинное слово в .txt файле. Формат выходного файла – CSV.

Реализация.

Реализация задачи осуществлялась на ОС Windows 7x64. Использовался hadoop 2.6.5, установлен в соответствии с инструкцией http://www.ics.uci.edu/~shantas/Install_Hadoop-2.6.0 on Windows10.pdf

Для сборки проекта использовалась IDE agnostic build Maven. pom.xml файл находится в репозитории. Для создания файловой системы HDFS и копирования данных был написан .bat файл hdfs.bat (в директории scripts). Скриншоты результатов представленны ниже.

Сборка производиться из командной строки командой <mvn package>

Рисунок 1 – Успешное выполнение тестов.

```
C:\Windows\system32\cmd.exe

D:\Prog\Work\hadoo_wdir\scripts\hdfs.bat

D:\Prog\Work\hadoo_wdir\scripts\call hadoop fs -mkdir /input
Found 1 items
-rw-r-r= 1 Segrey supergroup 171329 2017-12-09 01:28 /input/infile1.txt

D:\Prog\Work\hadoo_wdir\scripts\_
```

Рисунок 2 – Запуск скрипта. (Копирование файла в HDFS)

Запуск производиться командой:

hadoop jar homework1-0.0.1.jar homework1 /input /output

```
Администратор: C:\Windows\System32\cmd.exe
    mode : False
?/12/09 01:49:59 INFO mapreduce.Job: map 0% reduce 0%
?/12/09 01:50:06 INFO mapreduce.Job: map 100% reduce 0%
?/12/09 01:50:13 INFO mapreduce.Job: map 100% reduce 100%
?/12/09 01:50:15 INFO mapreduce.Job: Job job_1512763206212_0007 completed succe
    sfully
7/12/09 01:50:15 INFO mapreduce.Job: Counters: 49
                                         Pol:50:15 INFO mapreduce.Job: Counters: 49
File System Counters
FILE: Number of bytes read=256470
FILE: Number of bytes written=732091
FILE: Number of read operations=0
FILE: Number of large read operations=0
HDFS: Number of bytes read=138199
HDFS: Number of bytes written=22
HDFS: Number of read operations=6
HDFS: Number of read operations=6
HDFS: Number of write operations=0
HDFS: Number of write operations=2
Job Counters
                                           Job Counters
                                                                                    Launched map tasks=1
Launched reduce tasks=1
Rack-local map tasks=1
Total time spent by all maps in occupied slots (ms)=2879
Total time spent by all reduces in occupied slots (ms)=3484
Total time spent by all map tasks (ms)=2879
Total time spent by all map tasks (ms)=3484
Total time spent by all reduce tasks (ms)=3484
Total vcore-milliseconds taken by all map tasks=2879
Total vcore-milliseconds taken by all reduce tasks=3484
Total megabyte-milliseconds taken by all map tasks=2948096
Total megabyte-milliseconds taken by all reduce tasks=3567616
toe Framework
                                                                                  Internative Hilliseconds taken by all reduce Framework

Map input records=3490

Map output bytes=210846

Map output bytes=210846

Map output materialized bytes=256470

Input split bytes=105

Combine input records=0

Combine output records=0

Reduce input groups=4794

Reduce shuffle bytes=256470

Reduce input records=1

Reduce input records=1

Spilled Records=45618

Shuffled Maps =1

Failed Shuffles=0

Merged Map outputs=1

GC time elapsed (ms)=88

CPU time spent (ms)=2043

Physical memory (bytes) snapshot=454688768

Virtual memory (bytes) snapshot=541540352

Total committed heap usage (bytes)=300941312

Errors

PAD ID=0
                                           Map-Reduce Framework
Total committed heap
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
Bytes Read=138094
File Output Format Counters
Bytes Written=22
Job was successful!
D:\>hadoop fs -text /output/*
freestone-colour'd,18
D:\>
```

Рисунок 3 – Результат выполнения.